Primeira avaliação (A1)

Disciplina: Inferência Estatística (MSc) Instrutor: Luiz Max Carvalho Monitor: Isaque Pim

02 de Outubro de 2023.

- O tempo para realização da prova é de 3 horas e 55 minutos;
- Leia a prova toda com calma antes de começar a responder;
- Responda todas as questões sucintamente;
- Marque a resposta final claramente com um quadrado, círculo ou figura geométrica de sua preferência;
- (Mestrado) A prova vale 100 pontos. A pontuação restante é contada como bônus:
- (Mestrado) Apenas tente resolver a questão bônus quando tiver resolvido todo o resto;

1. Miss Independent

Seja X_1, \ldots, X_n variáveis aleatórias i.i.d absolutamente contínuas com densidade comum

$$f_{\theta}(x) = \theta e^{-\theta x} \mathbb{I}\{x > 0\},\,$$

onde $\theta > 0$ é desconhecido.

- a) (5 pontos) Encontre a densidade de θX_i ;
- b) (15 pontos) Seja, $X_{(1)} \leq \cdots \leq \ldots X_{(n)}$ as estatísticas de ordem e $\bar{X}=(X_1+\cdots+X_n)/n$ a média amostral. Mostre que \bar{X} e $X_{(1)}/X_{(n)}$ são independentes.

Conceitos trabalhados: suficiência mínima; ancilaridade; Teorema de Basu.

Nível de dificuldade: fácil.

Resolução: A densidade de $Y_i = h(X_i) = \theta X_i$ é $f_Y(y) = f_{\theta}(y/\theta) \left| \frac{\partial}{\partial y} h(y) \right| = f_{\theta}(y/\theta)/\theta$:

$$f_Y(y) = \exp(-y)\mathbb{I}\{y > 0\},\,$$

o que sugere que $Y_i \sim \text{exponencial}(1)$ e que Y_i é quantidade pivotal¹. Primeiro, vamos mostrar que \bar{X}_n é completa. Para isso, vamos estudar $S_n = \sum_{i=1}^n X_i$ e notar \bar{X}_n é transformação bijetora de S_n . Primeiro, vamos encontrar a distribuição de S_n através da sua função geradora de momentos.

$$M_S(t) = \prod_{i=1}^n \left\{ \frac{1}{1 - t/\theta} \right\},$$
$$= \left(\frac{1}{1 - t/\theta} \right)^n,$$

que é a MGF de uma Erlang 2 com parâmetros n e θ , cuja densidade 3 vale:

$$f_S(s) = \frac{\theta^n}{(n-1)!} s^{n-1} \exp(-\theta s) \mathbb{I}\{s > 0\}.$$

Agora, vamos considerar uma função mensurável $g: \mathbb{R}_+ \to \mathbb{R}$ de modo que

$$E_{\theta}[g(S_n)] = \int_0^\infty g(s) f_S(s) \, ds = 0,$$

de tal sorte que

$$\int_0^\infty g(s)s^{n-1}\exp(-\theta s)\,ds = 0. \tag{1}$$

Daqui, podemos fazer dois argumentos:

¹O conceito será visto em detalhes mais à frente no curso.

 $^{^2}$ Agner Krarup Erlang (1878-1929) foi um matemático, estatístico e engenheiro dinamarquês. E sim, isso é mesmo que dizer que S_n tem distribuição Gama com forma n e taxa $\theta.$

³Com respeito a Lebesgue em $\mathcal{B}(\mathbb{R})$.

- Note que (1) parece bastante a transformada de Laplace de g, L{g}(θ); particular, se (1) vale, vale também que L{g}(θ) = 0 para todo θ ∈ Ω. Mas sabemos que L{f}(t) = 0 para todo t se e somente se f(x) = 0 para todo x. É possível construir um argumento similar usando a transformada de Mellin⁴.
- Um argumento mais estatístico é notar que a Erlang pertence à família exponencial e que o espaço paramétrico é um aberto de \mathbb{R} , o que implica que T(s) = s é completa⁵ ver Teorema 3.19 de Keener (2010).

De posse da informação de que S_n é completa, concluímos que \bar{X}_n é completa. Ademais, $\frac{X_{(1)}}{X_{(n)}} = \frac{\theta X_{(1)}}{\theta X_{(n)}}$ é ancilar, já que é a razão entre duas variáveis aleatórias cuja distribuição não depende de θ . Pelo Teorema de Basu (Keener, 2010, Teorema 3.2.1), temos que $\bar{X}_n \perp \frac{X_{(1)}}{X_{(n)}}$.

Comentário: Uma questão bem simples, trabalhando os conceitos de forma bem transparente. O item a) é para ajudar a ver que a razão do mínimo e do máximo precisa ser ancilar. O resto foi trabalhado em aula.

2. You can't truncate sufficiency

Tome X_1, X_2, \ldots, X_n uma amostra aleatória de uma distribuição normal com média $\mu \in \mathbb{R}$ e variância $\sigma^2 \in \mathbb{R}_+$. Sabemos que média amostral $\bar{X}_n = n^{-1} \sum_{i=1}^n X_i$ e a variância amostral $\bar{V}_n = (n-1)^{-1} \sum_{i=1}^n \left(X_i - \bar{X}_n\right)^2$ são estatísticas suficientes para a distribuição normal com $\theta = (\mu, \sigma^2)$.

Em algumas situações, essas observações só podem acontecer dentro de uma região $A \in \mathcal{B}$. Por regularidade, assuma que $k(\theta) = P_{\theta}(X \in A) > 0$. Nesse caso, a distribuição apropriada para a nova variável aleatória restrita X^* é a distribuição condicional

$$P_{\theta}(X^* \in B) = P_{\theta}(X \in B | X \in A), \quad B \in \mathcal{B}.$$

Está distribuição é chamada de truncamento de X em um conjunto A.

- a) (10 pontos) Mostre que a média e a variância amostrais continuam sendo estatísticas suficientes para uma distribuição normal truncada em um intervalo A=(a,b) com $-\infty \leq a < b \leq \infty$.
- b) Seja $\mathcal{P} = \{P_{\theta}, \theta \in \Omega\}$ uma família de distribuições dominada por uma medida σ -finita μ . Seja A um boreliano. Considere P_{θ}^* o truncamento de P_{θ} em A e $\mathcal{P}^* = \{P_{\theta}^* : \theta \in \Omega\}$. Mostre que:
 - (10 pontos)* Se T é suficiente para $\mathcal{P},$ então é suficiente para $\mathcal{P}^*;$
 - (10 pontos)* Se T é completa para $\mathcal{P},$ então é completa para $\mathcal{P}^*.$

Conceitos trabalhados: suficiência; completude. Nível de dificuldade: Médio. Resolução:

⁴https://hal.science/hal-03152634v1/file/MELLIN.pdf

 $^{^5}$ Com n conhecido e θ desconhecido, é bom que se diga.

a) Seja $f(x|\mu,\sigma^2)$ a densidade da normal de média μ e variância σ^2 e $F(x|\mu,\sigma^2)$ sua função de distribuição acumulada. Seja $f^*(x|\mu,\sigma^2)$ a densidade do truncamento desta normal. Para simplificar a notação tome $\theta = (\mu, \sigma^2)$. É de amplo conhecimento que a normal truncada em (a, b) possui densidade igual a

 $f_{\theta}^*(x) = \frac{f_{\theta}(x)}{F_{\theta}(b) - F_{\theta}(a)}, \quad a < x < b,$

e vale 0 fora do do intervalo. Como a média e a variância amostral são

- suficientes para a normal não truncada, basta usar a mesma fatoração dada pelo teorema da fatoração e ver que ambas continuam sendo suficientes para a normal truncada (a densidade é a mesma a menos de uma constante e de uma variação no domínio que independe do parâmetro).
- b) Agora em um esquema mais geral temos que

$$P_{\theta}(E|A) = \frac{P_{\theta}(E \cap A)}{P_{\theta}(A)}$$

O denominador é uma constante em θ :

$$k(\theta) = \int_A dP_{\theta}.$$

Considere a indicadora do conjunto $A \mathbb{1}_A$. Por Radon-Nikodym temos

$$\frac{dP^*}{d\mu} = \frac{dP^*}{dP} \frac{dP}{d\mu} = \frac{1}{k(\theta)} \mathbb{1}_A f_{\theta}(x)$$

Note que $P_{\theta}(E \cap A) \leq P_{\theta}(E)$, então o truncamento mantém a medida de probabilidade dominada por μ . Por fim, a dependência no dado da densidade se manteve, e o teorema da fatorização vai garantir que T continuará suficiente. Para a completude, se T é completa para a distribuição não truncada, então

$$\mathbb{E}[\mathbb{1}_A g(T)] = 0 \iff \mathbb{1}_A g(T) = 0,$$

e pelo resultado anterior é fácil ver que na distribuição truncada

$$\mathbb{E}^*[g(T)] = \frac{1}{k(\theta)} \mathbb{E}[\mathbb{1}_A g(T)].$$

Fica claro então que a completude também se preserva.

Comentário: Não é necessário que a família seja dominada para que os resultados desta questão valham. A família ser dominada facilita no sentido de nos dar uma densidade de probabilidade e possibilitar invocar o teorema da fatorização. Você conseguiria mostrar os resultados dessa questão sem assumir a dominação da família?

3. For the non-canonical folk (20 pontos)

Para uma família exponencial no formato canônico, mostramos em aula que $\mathbb{E}[T_j] = \partial A(\nu)/\partial \nu_j$. Isso pode ser escrito em formato vetorial como $\mathbb{E}[T] = \nabla A(\nu)$. Deduza uma fórmula diferencial análoga para $\mathbb{E}_{\theta}[T]$ para uma família exponencial s-paramétrica que não está em formato canônico. Assuma que o novo espaço paramétrico, Ω , tem dimensão s.

Dica: Diferenciar sobre o sinal da integral resulta em um sistema linear de equações. Escreva essas equações em formato matricial.

Conceitos trabalhados: família exponencial.

Nível de dificuldade: Fácil.

Resolução: Para uma família exponencial s-paramétrica em formato canônico temos a seguinte identidade

$$e^{A(\nu)} = \int \exp(\langle \nu, T(x) \rangle) \cdot h(x) d\mu(x).$$

Aqui μ é uma medida em \mathbb{R}^n , $h: \mathbb{R}^n \to \mathbb{R}$ uma função mensurável não-negativa, $T = (T_1, \dots T_s)$ um vetor de funções mensuráveis do \mathbb{R}^n em \mathbb{R} e $\nu \in N \subseteq \mathbb{R}^s$ parâmetros de um espaço paramétrico adequado. Reparametrizando a distribuição substituindo ν por uma função $\nu: \Omega \to N$, de um novo espaço de parâmetros $\Omega \subset \mathbb{R}^s$ obtemos a nova identidade

$$e^{B(\theta)} = \int \exp(\langle \nu(\theta), T(x) \rangle) \cdot h(x) d\mu(x),$$

onde $B(\theta) = A(\nu(\theta))$. Agora, seguindo a dica e diferenciando a identidade sob a integral com respeito a θ obtemos

$$e^{B(\theta)} \frac{\partial B(\theta)}{\partial \theta_i} = \int \sum_{i=1}^s \frac{\partial \nu_j(\theta)}{\partial \theta_i} T_j(x) \exp(\langle \nu(\theta), T(x) \rangle) \cdot h(x) d\mu(x).$$

Podemos manipular os fatores que não dependem de x na integração. Dividindo ambos os lados por $e^{B(\theta)}$ e movendo o somatório obtemos

$$\frac{\partial B(\theta)}{\partial \theta_i} = \sum_{j=1}^s \frac{\partial \nu_j(\theta)}{\partial \theta_i} \mathbb{E}_{\theta}[T_j(x)].$$

Podemos compactar a notação para

$$\nabla B(\theta) = (D\nu(\theta))^T \cdot \mathbb{E}_{\theta}[T(x)]$$

Supondo a invertibilidade de $D\nu(\theta)$, obtemos a fórmula diferencial para $\mathbb{E}_{\theta}[T(x)]$ como sendo

$$\mathbb{E}_{\theta}[T(x)] = \left(D\nu(\theta)^T\right)^{-1} \nabla B(\theta).$$

Comentário: Note que com uma regra da cadeia multidimensional o resultado também sairia, e quase que de imediato.

4. Pfizer Inc.

Modelos de resposta à dosagem são de grande interesse da indústria farmacêutica. Uma possível aplicação seria na área de avaliação de risco de substâncias tóxicas, onde o realizador do experimento está interessado em estimar a probabilidade de alguma resposta (e.g, aparição de um tumor) em função da dosagem de toxina aplicada. Nesta questão vamos estudar as propriedades de suficiência mínima destes modelos.

Para isso, considere que vamos aplicar diferentes volumes de toxinas em ratos. $0 < d_1, < d_2 < \cdots < d_m$ foram as dosagens escolhidas para este estudo. Para cada dosagem, foi escolhida uma população de n_i ratos. Os n_i 's são fixos. Seja $x=(x_1,\ldots,x_m)$ o número de respostas à aplicação das doses, respectivamente. Isto é, para o i-ésimo grupo, de n_i ratos, x_i tiveram a reação desejada. Seja $p_{\theta}(d)$ a probabilidade de resposta a uma dose d>0, onde θ é p-dimensional com $(p\leq m)$ em um espaço de parâmetros Θ . A distribuição de probabilidade de x é dada por

$$f_M(x|\theta) = \prod_{i=1}^m \binom{n_i}{x_i} p_{\theta}(d_i)^{x_i} [1 - p_{\theta}(d_i)]^{n_i - x_i},$$

onde M representa uma escolha particular de modelo de resposta à dose (podemos escolher diferentes funções para modelar p_{θ}). Seja \mathcal{F}_{M} a família de distribuições induzida por M.

- a) (5 pontos) Mostre que T(x) = x é suficiente para \mathcal{F}_M para todo M.
- b) (15 pontos) Mostre o seguinte resultado preliminar. Seja \mathcal{P} uma família finita de distribuições com densidades p_i , $i=0,1,\ldots,k$, todas tendo o mesmo suporte. Então, a estatística

$$T(X) = \left(\frac{p_1(X)}{p_0(X)}, \frac{p_1(X)}{p_0(X)}, \dots, \frac{p_k(X)}{p_0(X)}\right)$$

é suficiente mínima.

Dica: Mostre primeiro que se U é uma estatística suficiente para \mathcal{P} , então a razão $\frac{p_i(x)}{p_j(x)}$ é uma função apenas de U(x).

c) (10 pontos) Seja A uma matriz $m \times m$ com seus elementos definidos por

$$A_{i,j} = \ln \left(\frac{p_{\theta_j}(d_i)[1 - p_{\theta_0}(d_i)]}{p_{\theta_0}(d_i)[1 - p_{\theta_i}(d_i)]} \right).$$

Mostre que se existirem vetores $(\theta_0, \theta_1, \dots, \theta_m)$ tais que a matriz A é invertível, então T(x) = x é suficiente mínima.

Conceitos trabalhados: suficiência; suficiência mínima . Nível de dificuldade: Médio. Resolução:

 $^{^6}$ Why did the statistician bring a toxin to the data analysis meeting? Because they wanted to add a little "poisonal" touch to their regression analysis...

- a) Imediato pelo Teorema da Fatorização. A função de densidade já é função de x.
- b) Tome o par de densidade p_i e p_j . Seguindo a dica, se U é suficiente para a família \mathcal{P} , então pelo teorema da fatorização existem funções g_i, g_j e h mensuráveis tais que

$$p_i(x) = g_i(U(x))h(x),$$

$$p_j(x) = g_j(U(x))h(x).$$

Tomando a razão de ambas as equações obtemos que p_i/p_j depende de x pela estatística suficiente U(x). Sabendo deste resultado, fica claro que a estatística T(X) do enunciado é função de qualquer estatística suficiente por ser um vetor de razões das densidades em \mathcal{P} . Basta então mostrar que T(X) é suficiente e ela será suficiente mínima por definição. Para cada i temos que

$$p_i(x) = (T(x))_i \cdot p_0(x).$$

Aqui p_0 está atuando como a função livre de parâmetro fixa. Para recuperar a densidade zero podemos definir a função depende do parâmetro para ser 1 em i=0. T(X) então é suficiente, e por ser função de toda estatística suficiente é suficiente mínima.

c) Se A é invertível, então A é uma aplicação linear bijetiva. Sabemos que suficiência mínima é preservada por bijeções. Defina T(x) como no item anterior para as densidades $p_i = f_M(x|\theta_i)$. Como estamos num espaço finito de densidades, T(x) é suficiente mínima. Vamos agora analisar a i-ésima linha do produto Ax.

$$(Ax)_{i} = \sum_{j=1}^{m} \ln \left(\frac{p_{\theta_{j}}(d_{i})[1 - p_{\theta_{0}}(d_{i})]}{p_{\theta_{0}}(d_{i})[1 - p_{\theta_{j}}(d_{i})]} \right) \cdot x_{j},$$

$$= \sum_{j=1}^{m} \ln \left(\frac{p_{\theta_{j}}^{x_{j}}(d_{i})[1 - p_{\theta_{0}}(d_{i})]^{x_{j}}}{p_{\theta_{0}}^{x_{j}}(d_{i})[1 - p_{\theta_{j}}(d_{i})]^{x_{j}}} \right),$$

$$= \ln \left(\prod_{j=1}^{m} \frac{p_{\theta_{j}}^{x_{j}}(d_{i})[1 - p_{\theta_{0}}(d_{i})]^{x_{j}}}{p_{\theta_{0}}^{x_{j}}(d_{i})[1 - p_{\theta_{j}}(d_{i})]^{x_{j}}} \right),$$

$$= \ln \left(\prod_{j=1}^{m} \frac{p_{\theta_{j}}^{x_{j}}(d_{i})[1 - p_{\theta_{j}}(d_{i})]^{-x_{j}}}{p_{\theta_{0}}^{x_{j}}(d_{i})[1 - p_{\theta_{0}}(d_{i})]^{-x_{j}}} \right),$$

$$= \ln \left(\frac{f_{M}(x|\theta_{j})}{f_{M}(x|\theta_{0})} \right).$$

como o logaritmo é bijetivo no domínio em questão e a composição de funções bijetivas é bijetiva, fica claro que x é estatística minimamente suficiente pois é uma bijeção da estatística minimamente suficiente encontrada no item anterior.

Comentário: A questão foi inspirada em Messig and Strawderman (1993). Em particular, o artigo em questão ilustra a existência de uma estatística completa

suficiente para uma família exponencial curvada (Keener, 2010, Cap 5), em particular uma estatística que é de dimensão maior que o parâmetro. Um ponto interessante a se aprender na questão é sobre a definição de estatística suficiente mínima. A dica dada no item b) induz a conclusão rápida de que T(X) é função de toda estatística suficiente, mas até mesmo constantes satisfazem isso. Deve ser mostrado também que T(X) é de fato uma estatística suficiente.

Bibliografia

Keener, R. W. (2010). Theoretical Statistics: Topics for a core course. Springer.

Messig, M. A. and Strawderman, W. E. (1993). Minimal sufficiency and completeness for dichotomous quantal response models. *The Annals of Statistics*, 21(4):2149-2157.